UNIWERSYTET GDAŃSKI

Laura Milczanowska

Nr albumu: 283025

Rola horyzontu czasowego w prognozowaniu upadłości przedsiębiorstw

Kierunek studiów: Informatyka i ekonometria
Poziom studiów: II stopnia
Profil studiów: ogólnoakademicki
Forma studiów: studia stacjonarne

Praca dyplomowa magisterska
wykonana pod kierunkiem
dr hab. Ewa Wycinka

Gdańsk, 2026

Spis treści

Wstęp 3

ROZDZIAŁ I. Upadłość przedsiębiorstwa i jej znaczenie 4

1.1.Definicja przedsiębiorstwa oraz pojęcie upadłości 4

1.2. Proces postępowania upadłościowego oraz skutki upadłości 8

1.3. Przyczyny upadłości przedsiębiorstwa 13

ROZDZIAŁ II. Metody prognozowania upadłości 18

2.1. Istota oraz rodzaje metod prognozowania 18

2.2. Modele prognozowania upadłości 23

2.3. Uwzględnianie horyzontu czasowego w prognozowaniu upadłości 28

ROZDZIAŁ III. Budowa modeli ryzyka upadłości w różnych horyzontach czasowych .33

3.1. Charakterystyka próby badawczej i wstępna analiza danych 33

3.2. Modele skoringowe ryzyka upadłości 38

3.3. Wyniki prognoz upadłości z różnym horyzontem czasowym 43

Zakończenie 51

Bibliografia 53

Spis tabel 55

Spis wykresów 56

Spis ilustracji 56

Wstęp

Prognozowanie upadłości przedsiębiorstw stanowi jedno z kluczowych zagadnień współczesnych finansów i ekonometrii. Zdolność do wczesnego identyfikowania podmiotów zagrożonych niewypłacalnością ma istotne znaczenie zarówno dla wierzycieli, inwestorów, jak i instytucji nadzorczych, które dążą do minimalizacji ryzyka kredytowego i systemowego. Rosnąca dostępność danych finansowych oraz rozwój metod ilościowych sprawiają, że modele predykcji upadłości zyskują na znaczeniu praktycznym i naukowym.

W literaturze przedmiotu szczególną uwagę poświęca się skuteczności modeli klasyfikacyjnych w zależności od zastosowanego horyzontu czasowego prognozowania. Intuicja podpowiada, że im bliżej momentu bankructwa, tym sygnały finansowe powinny być wyraźniejsze, a modele trafniejsze. Założenie to rzadko bywa jednak poddawane rygorystycznej weryfikacji empirycznej na jednorodnych zbiorach danych i przy użyciu spójnej metodologii. Niniejsza praca podejmuje próbę wypełnienia tej luki.

Celem pracy jest zbadanie, w jaki sposób horyzont czasowy wpływa na zdolność dyskryminacyjną modeli do prognozowania upadłości przedsiębiorstw. Podstawową metodą badawczą jest analiza ilościowa oparta na modelach regresji logistycznej, szacowanych dla pięciu horyzontów czasowych - od jednego do pięciu lat przed ogłoszeniem upadłości. W procesie budowy modeli zastosowano podejście charakterystyczne dla modeli scoringowych, polegające na przekształceniu zmiennych ciągłych w quasi-ciągłe zmienne oparte na wskaźniku WoE (Weight of Evidence). Podejście to zwiększa interpretowalność modelu, pozwala na nieliniowe odwzorowanie relacji między predyktorami a ryzykiem upadłości oraz ogranicza wpływ wartości odstających na wyniki estymacji.

Praca składa się z trzech rozdziałów. Rozdział pierwszy poświęcony jest teorii upadłości przedsiębiorstw. Omówiono w nim definicję i pojęcie upadłości, przebieg postępowania upadłościowego oraz jego skutki, a także główne przyczyny niewypłacalności podmiotów gospodarczych. Rozdział drugi przedstawia metody prognozowania upadłości. Omówiono w nim istotę i rodzaje metod prognozowania, przegląd modeli stosowanych w literaturze oraz szczególną rolę horyzontu czasowego w procesie predykcji. Rozdział trzeci ma charakter empiryczny. Opisano w nim charakterystykę próby badawczej, wstępną analizę danych, zastosowaną metodykę budowy modelu scoringowego, a także wyniki prognoz upadłości uzyskane dla pięciu różnych horyzontów czasowych.

Rozdział III. Budowa modeli ryzyka upadłości w różnych horyzontach czasowych

3.1. Charakterystyka próby badawczej i wstępna analiza danych

Do przeprowadzenia analizy został wykorzystany zbiór danych opracowany przez Ziębę i in. (2016), który jest dostępny w repozytorium UCI Machine Learning Repository i dotyczy kondycji finansowej polskich przedsiębiorstw z sektora produkcyjnego[63]. Autorzy wyodrębnili 64 wskaźniki finansowe opracowane na podstawie sprawozdań finansowych. Te firmy, które zbankrutowały, analizowano w latach 2000-2012, natomiast firmy nadal funkcjonujące badano w okresie 2007-2013. Metodologia zebrania danych treningowych została przedstawiona w Tabeli 3.

Tabela 3. Metodologia zbierania danych treningowych

Nazwa	Kryterium	Wybór
sektor	najwyższa liczba upadłości w sektorze w porównaniu z innymi sektorami	sektor produkcyjny
baza danych sprawozdań finansowych	dostępność baz danych	EMIS
okres	dostępność sprawozdań finansowych	5 lat przed upadłością w okresie 2007-2013; lata 2000-2012 dla firm nadal działających
Firmy, które zbankrutowały	dostępność co najmniej jednego sprawozdania finansowego w analizowanym okresie pięciu lat przed upadłością firmy	prawie 700 spośród 1000 zbankrutowanych przedsiębiorstw zostało wybranych w okresie 2007-2013 (przeanalizowano prawie 2 400 sprawozdań finansowych)
firmy nadal działające	dostępność minimum trzech kolejnych sprawozdań finansowych w okresie 2000-2012	ponad 10 000 spośród 17 000 nadal funkcjonujących firm zostało wybranych (wzięto pod uwagę ponad 65 tysięcy sprawozdań finansowych)
wskaźniki finansowe	stosowane w modelach zintegrowanych i analizie finansowej	przeanalizowano 64 wskaźniki finansowe (zob. Tabela 4)

Źródło: Zięba M., Tomczak S., Tomczak J., *Ensemble Boosted Trees with Synthetic Features Generation in Application to Bankruptcy Prediction*, Expert Syst. Appl., *58*, 93-101, 2016, s. 12

Wyróżnionych zostało pięć podziałów, różniących się okresem prognozowania:

- *1stYear* - dane dotyczą wskaźników finansowych pochodzących z pierwszego roku okresu badania wraz ze zmienną binarną określającą status bankructwa po 5 latach. W zbiorze znajduje się 7027 przypadków, z czego 271 dotyczy firm, które zbankrutowały po pięciu latach. Pozostałe 6756 firm, to te które nie zbankrutowały po pięciu latach.

[63] Link do danych: https://archive.ics.uci.edu/dataset/365/polish+companies+bankruptcy+data, data pobrania: 03.04.2025r.

- *2ndYear* - dane dotyczą wskaźników finansowych pochodzących z drugiego roku okresu badania wraz ze zmienną binarną określającą status bankructwa po 4 latach. W zbiorze znajduje się 10173 przypadków, z czego 400 dotyczy firm, które zbankrutowały po czterech latach. Pozostałe 9773 firm, to te które nie zbankrutowały po czterech latach.
- *3rdYear* - dane dotyczą wskaźników finansowych pochodzących z trzeciego roku okresu badania wraz ze zmienną binarną określającą status bankructwa po 3 latach. W zbiorze znajduje się 10503 przypadków, z czego 495 dotyczy firm, które zbankrutowały po trzech latach. Pozostałe 10008 firm, to te które nie zbankrutowały po trzech latach.
- *4thYear* - dane dotyczą wskaźników finansowych pochodzących z czwartego roku okresu badania wraz ze zmienną binarną określającą status bankructwa po 2 latach. W zbiorze znajduje się 9792 przypadków, z czego 515 dotyczy firm, które zbankrutowały po dwóch latach. Pozostałe 9277 firm, to te które nie zbankrutowały po dwóch latach.
- *5thYear* - dane dotyczą wskaźników finansowych pochodzących z piątego roku okresu badania wraz ze zmienną binarną określającą status bankructwa po 1 roku. W zbiorze znajduje się 5910 przypadków, z czego 410 dotyczy firm, które zbankrutowały po roku. Pozostałe 5500 firm, to te które nie zbankrutowały po roku.

Na tym etapie można zauważyć, że struktura próby badawczej pod względem statusu bankructwa jest silnie zróżnicowana. Zdecydowaną mniejszość stanowią firmy, wobec których ogłoszono upadłość.

Każdy zbiór danych zawiera 64 wskaźniki finansowe oraz kolumnę *id*, która pełni rolę identyfikatora firmy i zmienną *class*, która określa status bankructwa. Wszystkie zmienne zostały opisane w tabeli poniżej.

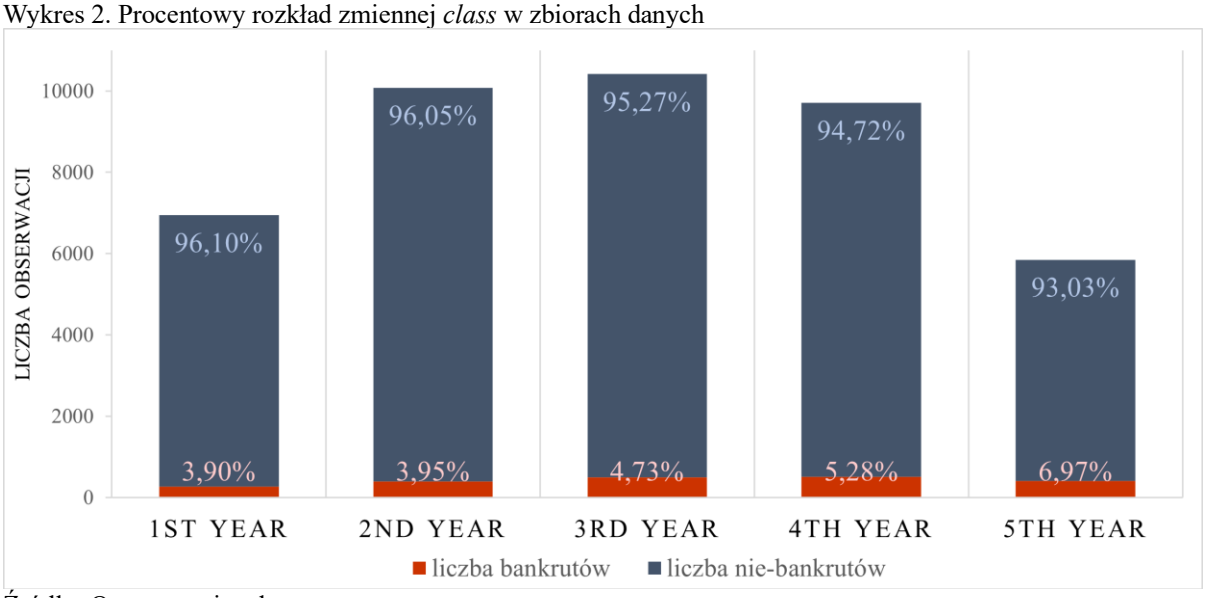
Tabela 4. Zestaw zmiennych występujący w zbiorze danych

	Opis zmiennej		**Opis zmiennej**
id	numer firmy	X33	koszty operacyjne / zobowiązania krótkoterminowe
X1	zysk netto / aktywa ogółem	X34	koszty operacyjne / zobowiązania ogółem
X2	zobowiązania ogółem / aktywa ogółem	X35	zysk ze sprzedaży / aktywa ogółem
X3	kapitał obrotowy / aktywa ogółem	X36	sprzedaż ogółem / aktywa ogółem
X4	aktywa obrotowe / zobowiązania krótkoterminowe	X37	(aktywa obrotowe - zapasy) / zobowiązania długoterminowe
X5	[(gotówka + papiery wartościowe krótkoterminowe + należności - zobowiązania krótkoterminowe) / (koszty operacyjne - amortyzacja)] * 365	X38	kapitał stały / aktywa ogółem
X6	zyski zatrzymane / aktywa ogółem	X39	zysk ze sprzedaży / sprzedaż
X7	EBIT (zysk przed odliczeniem podatków i odsetek) / aktywa ogółem	X40	(aktywa obrotowe - zapasy - należności) / zobowiązania krótkoterminowe
X8	wartość księgowa kapitału własnego / zobowiązania ogółem	X41	zobowiązania ogółem / ((zysk z działalności operacyjnej + amortyzacja) * (12/365))

X9	sprzedaż / aktywa ogółem	X42	zysk z działalności operacyjnej / sprzedaż
X10	kapitał własny / aktywa ogółem	X43	rotacja należności + rotacja zapasów w dniach (w dniach)
X11	(zysk brutto + pozycje nadzwyczajne + koszty finansowe) / aktywa ogółem	X44	(należności * 365) / sprzedaż
X12	zysk brutto / zobowiązania krótkoterminowe	X45	zysk netto / zapasy
X13	(zysk brutto + amortyzacja) / sprzedaż	X46	(aktywa obrotowe - zapasy) / zobowiązania krótkoterminowe
X14	(zysk brutto + odsetki) / aktywa ogółem	X47	(zapasy * 365) / koszt sprzedanych produktów
X15	(zobowiązania ogółem * 365) / (zysk brutto + amortyzacja)	X48	EBITDA (zysk z działalności operacyjnej - amortyzacja) / aktywa ogółem
X16	(zysk brutto + amortyzacja) / zobowiązania ogółem	X49	EBITDA / sprzedaż
X17	aktywa ogółem / zobowiązania ogółem	X50	aktywa obrotowe / zobowiązania ogółem
X18	zysk brutto / aktywa ogółem	X51	zobowiązania krótkoterminowe / aktywa ogółem
X19	zysk brutto / sprzedaż	X52	(zobowiązania krótkoterminowe * 365) / koszt sprzedanych produktów
X20	(zapasy * 365) / sprzedaż	X53	kapitał własny / aktywa trwałe
X21	sprzedaż (n) / sprzedaż (n-1)	X54	kapitał stały / aktywa trwałe
X22	zysk z działalności operacyjnej / aktywa ogółem	X55	kapitał obrotowy
X23	zysk netto / sprzedaż	X56	(sprzedaż - koszt sprzedanych produktów) / sprzedaż
X24	zysk brutto (z 3 lat) / aktywa ogółem	X57	(aktywa obrotowe - zapasy - zobowiązania krótkoterminowe) / (sprzedaż - zysk brutto - amortyzacja)
X25	(kapitał własny - kapitał zakładowy) / aktywa ogółem	X58	koszty ogółem / sprzedaż ogółem
X26	(zysk netto + amortyzacja) / zobowiązania ogółem	X59	zobowiązania długoterminowe / kapitał własny
X27	zysk z działalności operacyjnej / koszty finansowe	X60	sprzedaż / zapasy
X28	kapitał obrotowy / aktywa trwałe	X61	sprzedaż / należności
X29	logarytm z aktywów ogółem	X62	(zobowiązania krótkoterminowe * 365) / sprzedaż
X30	(zobowiązania ogółem - gotówka) / sprzedaż	X63	sprzedaż / zobowiązania krótkoterminowe
X31	(zysk brutto + odsetki) / sprzedaż	X64	sprzedaż / aktywa trwałe
X32	(zobowiązania bieżące * 365) / koszt sprzedanych produktów	class	zmienna binarna: (0) nie bankrut, (1) bankrut

Na początku z każdego zbioru danych zostały usunięte duplikaty, które nieznacznie zmniejszyły liczebność obserwacji. W pierwszym zbiorze liczba obserwacji zmniejszyła się o 82 firmy, bez naruszenia liczebności bankrutów (271). W drugim zbiorze usunięto 90 obserwacji, w tym liczba podmiotów niewypłacalnych pomniejszyła się o dwie firmy. Trzeci zbiór zredukowano o 87 firmy, w tym 3 firmy posiadały status bankructwa. Z czwartego zbioru uśnięto 82 obserwacje, z czego 2 firmy to bankruci. Piąty zbiór zawiera 60 firm mniej, w tym 2 firmy były niewypłacalne . Na Wykresie 2 przedstawiono proporcję klas w każdym z badanych zbiorów. Dzięki wstępnej analizie danych, zidentyfikowany został problem niezbalansowania danych. Oznacza to, że dla zmiennej zależnej *class* występuje dysproporcja liczebności wariantów. Zdecydowaną mniejszość (od 3,90% do 6,97%) stanowią firmy, które zbankrutowały.

Wykres 2. Procentowy rozkład zmiennej *class* w zbiorach danych



Źródło: Opracowanie własne

Dla wskaźników finansowych, w każdym z pięciu zbiorów danych występują braki danych. Przykładowo, dla pierwszego okresu prognozowania braki danych stanowią 1,30% całości. Biorąc pod uwagę wszystkie dane w tym zbiorze, puste komórki stanowią niewielką część. Natomiast rozpatrując indywidualnie każdą zmienną oraz każdą obserwację, w niektóry przypadkach brakujące dane stanowią wysoki procent. Podsumowanie braków danych dla każdego zbioru zostało przedstawione w Tabeli 5.

Tabela 5. Rozkład braków danych w poszczególny zbiorach

	1st Year	***2nd Year***	***3rd Year***	***4th Year***	***5th Year***
Liczba obserwacji	6945	10083	10416	9710	5850
Ogólny % braków	1,30%	1,87%	1,48%	1,40%	1,24%
Ile zmiennych zawiera braki	49	64	44	62	49
Zmienne z największym % braków	X37 (39,01%) X21 (23,20%) X27 (4,45%)	X37 (44,48%) X21 (31,33%) X27 (6,97%) X60 (5,35%) X45 (5,33%)	X37 (45,15%) X21 (7,73%) X27 (6,85%) X60 (5,65%) X45 (5,65%)	X37 (45,46%) X27 (6,54%) X60 (6,31%) X45 (6,30%)	X37 (43,16%) X27 (6,67%) X45 (4,55%) X60 (4,55%)
ID firmy z największym % braków	5396 (62,50%)	7357 (56,25%)	7510 (54,69%)	2899 (50%)	4885 (64,06%)

Źródło: Opracowanie własne

Schemat występowania brakujących danych w zmiennych jest powtarzalny. W każdym ze zbiorów, zmienna X37 posiada największy deficyt informacji. Te zjawisko może występować najprawdopodobniej dlatego, że część firm nie posiada zobowiązań długoterminowych i wyznaczenie tego wskaźnika staje się niemożliwe. Warto zwrócić uwagę na zmienną X21, która porównuje sprzedaż w roku *n* z rokiem poprzednim. Wysoki poziom

braków w dwóch pierwszym zbiorach, może być spowodowany występowaniem firm niedawno zarejestrowanych, które nie posiadają ciągłości historycznej danych. Zmienna X27 również wygenerowała znaczącą liczbę braków, co również może być spowodowane nie posiadaniem kosztów finansowych przez przedsiębiorstwa. Do kosztów finansowych należą odsetki (i prowizje od zaciągniętych kredytów i pożyczek), odsetki za zwłokę w spłacie zobowiązań, wartość sprzedanych aktywów finansowych, ujemne różnice kursowe, itp.[64].

Przeprowadzona została również analiza sprawdzająca, czy braki danych znacząco wyróżniają się na tle przedsiębiorstw bankrutujących. Można przypuszczać, że firmy na skraju kryzysu, nie podawały dokładnych informacji, aby ukryć niepożądaną sytuację finansową. Do weryfikacji tej hipotezy, skorzystano z testu U Manna - Whitneya[65]. Jest to test nieparametryczny, który nie zakłada normalności rozkładu danych. Sprawdza, czy dwie grupy, które są niezależne, różnią się od siebie. Na jego podstawie ocenione zostało czy występuje różnica w liczbie braków danych między firmami, które zbankrutowały, a tymi, które przetrwały. Utworzona została nowa zmienna *liczba braków*, zliczająca dla ilu wskaźników finansowych brakuje informacji w poszczególnych przedsiębiorstwach. Wyniki testu wraz z średnią oraz maksymalną liczbą braków reprezentuje Tabela 6. W każdym zbiorze istnieje statystycznie istotna różnica, ponieważ wartość *p,* przy przyjętym poziomie istotności 0,05 wyniosła 0,00. Porównanie ze sobą średnich rang wykazało, że większa ilość braków występuję dla kategorii „1", czyli bankrutów. Test potwierdził zatem, że braki danych prawdopodobnie nie są losowe i dla firm bankrutujących częściej występuje deficyt informacji. Dodatkowo ciekawą obserwacją, jest występowanie większego maksimum braków w grupie nie-bankrutów. Pomimo tego, średnia liczba braków dla tej grupy jest niższa, niż dla grupy przeciwnej.

Tabela 6. Wyniki testu U Manna - Whitneya oraz statystyki opisowe zmiennej zależnej *liczba braków* oraz zmiennej grupującej *class*

	class	***1st Year***	***2nd Year***	***3rd Year***	***4th Year***	***5th Year***
p wartość	-	0,00	0,00	0,00	0,00	0,00
Średnia ranga	0	3453,03	4991,45	5131,98	4772,83	2851,56
	1	**5033,87**	**6272,10**	**6748,72**	**6337,59**	**3911,69**
Średnia liczba braków	0	0,80	1,18	0,92	0,86	0,73
	1	1,56	1,70	1,48	1,55	1,58

[64] Artienwicz N., Bartoszewicz A., Cygańska M., Wójtowicz P., *Kształtowanie wyniku finansowego w Polsce. Teoria - praktyka - stan badań.,* Wydawnictwo IUS PUBLICUM, Katowice 2020, s.17
[65] Mann H., Whitney D., *On a test of whether one of two random variables is stochastically larger than the other.* Annals of Mathematical Statistics, 1947

Maksimum braków	0	40	36	35	32	41
	1	9	23	25	25	28

Źródło: Opracowanie własne.

3.2. Modele skoringowe ryzyka upadłości

W literaturze przedmiotu przedstawiono szerokie spektrum metod wykorzystywanych w prognozowaniu upadłości przedsiębiorstw, obejmujące m.in. analizę dyskryminacyjną, regresję logistyczną, drzewa decyzyjne, lasy losowe, metody boostingowe, sieci neuronowe, natomiast w niniejszej pracy zastosowana została metodyka budowy modeli scoringowych.

W dalszej części, do prognozowania upadłości przedsiębiorstw wykorzystany zostanie model dyskryminacyjny w postaci regresji logistycznej, która umożliwia między innymi przewidywanie, z jakim prawdopodobieństwem (dla zmiennej zależnej binarnej) wystąpi zjawisko, określone wartością 1[66]. Przed jej zastosowaniem należy spełnić założenie odpowiedniej liczby obserwacji. Odnosząc się do zbioru danych *1stYear*, ponieważ tutaj pojawia się najmniej przypadków bankructwa (271), maksymalna liczba predyktorów powinna wynosić 27. Aby wybrać najlepsze zmienne objaśniające, na początku posłużono się miarą *Information Value (IV)*, która pozwala na określenie siły predykcyjnej zmiennych[67]. Następnie za pomocą modelu Random Forest nadano rangę każdej zmiennej. Obliczono średnią rangę i wybrano 15 najlepszych predyktorów. Na koniec sprawdzono skorelowanie tych zmiennych i odrzucono te wykazujące silne powiązanie, aby zastosować metodę dyskretyzacji zmiennych.

Dla czterech z pięciu pierwszych zbiorów zastosowany został próg odrzucenia zmiennych na poziomie IV < 0,10. Dla *5thYear* próg został zawyżony do 0,20, ponieważ tylko jedna zmienna wykazała wartość mniejszą niż 0,10. Na tej podstawie, ze zbiorów wyeliminowane zostały zmienne przedstawione w Tabeli 7, uporządkowane według rosnącej ważności (od najsłabszego predyktora).

[66] Raczkiewicz D., *Zastosowanie analizy regresji w reprezentacyjnych badaniach społeczno-gospodarczych*, Ekonometria 51:31-47, 2016, s. 38

[67] Rojas H., Alvarez C., Rojas N., *Statistical Hypothesis Testing for Information Value (IV)*, Journal of Statistical Theory and Applications, 24:1196-1216, 2025, s.1197

Tabela 7. Zmienne objaśniające wyeliminowane na podstawie kryterium IV

Zbiór	Usunięte zmienne	Liczba usuniętych zmiennych
1stYear	X37, X47, X20, X36, X44, X61, X43, X64, X59, X60, X29, X9	12
2ndYear	X47, X61, X64, X59, X20, X29, X44, X43, X36, X60, X37, X9, X21, X34, X48, X49	16
3rdYear	X64, X37, X36, X47, X29, X44, X59, X61, X43, X20, X60, X34	12
4thYear	X37, X47, X36, X64, X43, X61, X44, X20, X60	9
5thYear	X37, X36, X47, X64, X20, X60, X34	7

Źródło: opracowanie własne

Dla każdego z pięciu zbiorów zbudowano oddzielny model Random Forest. Zastosowano ten model, ponieważ jest łatwy w użyciu, radzi sobie nieliniowością, brakami danych oraz z wartościami odstającymi. Model skonstruowano w oparciu o 500 drzew decyzyjnych, przy czym w każdym węźle losowano 8 predyktorów. Ustalono minimalną liczność węzła na poziomie 80 obserwacji, maksymalna liczba węzłów wynosiła 100 oraz maksymalna głębokość drzewa wynosiła 10 poziomów. Proces uczenia oparto na podpróbkach typu bootstrap (50% zbioru treningowego), przy zachowaniu równych kosztów błędnej klasyfikacji oraz równych prawdopodobieństw *a priori*.

Ocena jakości modeli, zastosowanych wyłącznie w celu selekcji predyktorów, wykazała wystarczającą dokładność. Dla zbioru *1stYear*, model poradził sobie najgorzej. Mimo wysokiej ogólnej trafności modelu na poziomie 97% (ogólna ocena ryzyka wyniosła 0,028), zaobserwowano trudność algorytmu w poprawnej klasyfikacji jednostek określonych jako „bankrut". Algorytm zaklasyfikował poprawnie tylko 28,6% bankrutów. Wynika to z niskiej liczebności tej klasy. W zbiorze *2ndYear* wartość oceny ryzyka wyniosła 13,9%, co oznacza poprawną klasyfikację na poziomie około 86%. Model wykrył poprawnie 52,2% bankrutów. Dla zbioru *3rdYear* trafność modelu wyniosła 91%, ale wykrywalność bankrutów to zaledwie 41,9%. W zbiorze *4thYear* trafność to 89,7% i algorytm wykrył 45,3% bankrutów. Dla *5thYear* wyniki prezentują się najlepiej, ponieważ poprawna klasyfikacja wyniosła 91,1% i bankruci zostali poprawnie sklasyfikowani w 70,3%, co daje najwyższy wynik względem innych zbiorów.

Następnie, w każdym zbiorze posortowano zmienne od najwyższej wartości ważności w modelu i nadano im numer miejsca pozycji (gdzie 1 = zmienna najbardziej istotna).

Wyliczono średnią rangę oraz wybrano 15 zmiennych z najwyższą wartością. W Tabeli 8 znajdują się wyselekcjonowane zmienne wraz z opisem.

Tabela 8. Ranking zmiennych wybranych za pomocą modeli Random Forest

		ranga					średnia ranga	opis zmiennej
		1stYear	*2ndYear*	*3rdYear*	*4thYear*	*5thYear*		
1	**X27**	1	1	1	1	1	1	zysk z działalności operacyjnej / koszty finansowe
2	**X24**	4	3	2	2	9	4	zysk brutto (z 3 lat) / aktywa ogółem
3	**X46**	10	2	3	3	3	4,2	(aktywa obrotowe - zapasy) / zobowiązania krótkoterminowe
4	**X26**	3	15	6	7	20	10,2	(zysk netto + amortyzacja) / zobowiązania ogółem
5	**X22**	11	8	10	14	11	10,8	zysk z działalności operacyjnej / aktywa ogółem
6	**X35**	22	4	17	9	4	11,2	zysk ze sprzedaży / aktywa ogółem
7	**X5**	6	7	8	15	25	12,2	[(gotówka + papiery wartościowe krótkoterm. + należności - zobowiązania krótkoterm.) / (koszty oper. - amortyzacja)] * 365
8	**X13**	26	9	7	8	17	13,4	(zysk brutto + amortyzacja) / sprzedaż
9	**X39**	34	5	22	13	7	16,2	zysk ze sprzedaży / sprzedaż
10	**X42**	16	17	27	18	5	16,6	zysk z działalności operacyjnej / sprzedaż
11	**X45**	28	10	28	10	10	17,2	zysk netto / zapasy
12	**X38**	14	13	23	26	13	17,8	kapitał stały / aktywa ogółem
13	**X25**	17	24	15	28	8	18,4	(kapitał własny - kapitał zakładowy) / aktywa ogółem
14	**X58**	20	20	4	6	48	19,6	koszty ogółem / sprzedaż ogółem
15	**X16**	49	12	11	11	19	20,4	(zysk brutto + amortyzacja) / zobowiązania ogółem

Źródło: Opracowanie własne

Pierwsze miejsce we wszystkich 5 latach zajęła zmienna X27. To silny sygnał, że zysk z działalności operacyjnej / koszty finansowe jest fundamentalnym predyktorem bankructwa niezależnie od horyzontu czasowego.

Do zbadania współzależności pomiędzy analizowanymi wskaźnikami finansowymi przedsiębiorstw wykorzystano współczynnik korelacji rang Spearmana. Wskaźniki finansowe spółek charakteryzują się zazwyczaj asymetrią, brakiem rozkładu normalnego oraz obecnością obserwacji skrajnych, wynikających np. z gwałtownego pogorszenia kondycji finansowej. Współczynnik Spearmana, jako metoda oparta na rangowaniu wartości, wykazuje wysoką odporność na anomalie w danych i pozwala na wykrycie nie tylko zależności liniowych, ale wszelkich monotonicznych związków między zmiennymi. Wyniki korelacji (Tabela 9) wykazały, że we wszystkich zbiorach silnie powiązana była para zmiennych X26 oraz X16 z wartościami w przedziale 0,992 - 0,994. Zmienna X26 jest o wiele wyżej w rankingu predyktorów, dlatego zmienna X16 nie będzie brana pod uwagę w dalszej analizie. W czterech z pięciu zbiorach silnie skorelowaną są pary: X35 oraz X22, X42 oraz X22, X42 oraz X39. Z

tej grupy - zmienna X22 ma najwyższą średnią rangę w rankingu, a więc zmienne X35 oraz X42 zostały wyeliminowane. Podsumowując, do dalszej analizy uwzględniono 12 zmiennych: X27, X24, X46, X26, X22, X5, X13, X39, X45, X38, X25, X58.

Tabela 9. Pary zmiennych silnie skorelowane we wszystkich zbiorach danych

1st Year	*2nd Year*	*3rd Year*	*4th Year*	*5th Year*
X26 i X16 = 0,992 X35 i X22 = 0,934 X42 i X39 = 0,931	**X26 i X16 = 0,994** X22 i X42 = 0,917 X35 i X22 = 0,920 X42 i X39 = 0,904 X39 i X35 = 0,918	**X26 i X16 = 0,994** X35 i X22 = 0,915 X42 i X22 = 0,921 X35 i X39 = 0,920 X39 i X42 = 0,900	**X26 i X16 = 0,993** X42 i X22 = 0,920 X35 i X39 = 0,923	**X26 i X16 = 0,992** X42 i X22 = 0,913 X35 i X22 = 0,904 X39 i X35 = 0,913

Źródło: Opracowanie własne

Wskaźniki finansowe są zmiennymi ciągłymi, oznacza to, że mogą przyjąć dowolną wartość z określonego przedziału. Regresja logistyczna zakłada liniową zależność między predyktorem, a logitem. Po wyborze reprezentantów, kolejnym etapem przed budową modelu regresji logistycznej jest dyskretyzacja zmiennych. W niniejszej pracy zastosowano podejście charakterystyczne dla modeli scoringowych, polegające na przekształceniu zdyskretyzowanych zmiennych ciągłych w tzw. quasi-ciągłe zmienne *WoE (weight of evidence* mierzy różnicę między kategoriami zmiennej[68]). Poprzez zamianę ciągłego, nieliniowego wskaźnika na przedziały, przypisywane są im wagi, które pokazują jakie ryzyko występuje w określonych przedziałach. Dodatkowo ekstremalne wartości, po dopasowaniu ich do pierwszego lub ostatniego przedziału, nie będą wpływać negatywnie na parametry modelu. Dla tych samych predyktorów zostały utworzone identyczne przedziały w każdym zbiorze, aby modele były lepiej porównywalne ze względu na badany horyzont czasowy. Nie jest to prosta metoda, ze względu na różnorodność zbiorów danych, zarówno ilościową jak i jakościową. Przedziały tworzono w taki sposób, aby procent złych przypadków przekraczał 5%. Natomiast różnica *WoE* między przedziałami osiągała co najmniej 20 punktów. Proces podziału przeprowadzono w sposób manualny, tak aby uzyskać kompromis pomiędzy maksymalizacją wartości wskaźnika IV, a zachowaniem monotoniczności trendu dla zmiennej w każdym zbiorze.

Tabela 10 przedstawia wyniki dyskretyzacji dwunastu zmiennych objaśniających wykorzystanych w budowie modeli scoringowych wraz z kierunkiem trendu wartości WoE w wyodrębnionych przedziałach. Jedenaście spośród dwunastu zmiennych charakteryzuje się rosnącym trendem WoE, co oznacza że wraz ze wzrostem wartości wskaźnika finansowego

[68] Rojas H., Alvarez C., Rojas N., *Statistical Hypothesis Testing for Information Value (IV)*, Journal of Statistical Theory and Applications, 24:1196-1216, 2025, s.1197

maleje ryzyko niewypłacalności przedsiębiorstwa Wyjątek stanowi zmienna X58, dla której trend jest malejący - rosnący udział kosztów w przychodach ze sprzedaży wiąże się z pogorszeniem kondycji finansowej i wzrostem ryzyka, co jest zgodne z intuicją ekonomiczną.

Tabela 10. Przedziały dyskretyzacji oraz kierunek trendu WoE zmiennych objaśniających

Zmienna	**Przedziały**	**Trend**
X5	(-∞; -1,6081>, (-1,6081; 15,965>, (15,965; +∞)	rosnący
X13	(-∞; 0,028>, (0,028; 0,088>, (0,088; +∞)	rosnący
X22	(-∞; -0,0727>, (-0,0727; 0,087>, (0,087; +∞)	rosnący
X24	(-∞; 0,015>, (0,015; 0,15>, (0,15; +∞)	rosnący
X25	(-∞; 0,039481>, (0,039481; 0,39776>, (0,39776; 0,55951>, (0,55951; +∞)	rosnący
X26	(-∞; 0,09>, (0,09; 0,22>, (0,22; +∞)	rosnący
X27	(-∞; -0,7504>, (-0,7504; +∞)	rosnący
X38	(-∞; 0,246>, (0,246; 0,3732>, (0,3732; 0,6515>, (0,6515; 0,7119>, (0,7119; +∞)	rosnący
X39	(-∞; -0,0474>, (-0,0474; 0,0006>, (0,0006; 0,0551>, (0,0551; +∞)	rosnący
X45	(-∞; 0,053>, (0,053; 0,328>, (0,328; +∞)	rosnący
X46	(-∞; 0,5>, (0,5; 1>, (1; +∞)	rosnący
X58	(-∞; 0,9>, (0,9; 1,04>, (1,04; +∞)	malejący

Źródło: Opracowanie własne

Tabela 11 przedstawia wartości współczynnika IV dla zmiennych objaśniających przed i po przeprowadzeniu dyskretyzacji, w rozbiciu na pięć horyzontów czasowych (rok 1-5). We wszystkich przypadkach dyskretyzacja powoduje obniżenie wartości IV. Scalenie wartości ciągłych w przedziały nieuchronnie wiąże się z pewną utratą siły predykcyjnej zmiennych. Skala tej utraty jest jednak umiarkowana i akceptowalna, a uzyskane wartości IV po dyskretyzacji w większości przypadków nadal wskazują na średnią lub wysoką siłę predykcyjną zmiennych. Wyraźnie najwyższe wartości IV odnotowano dla horyzontu 5-letniego (ROK 5), gdzie niemal wszystkie zmienne osiągają najwyższą siłę predykcyjną, co może wskazywać na to że długoterminowe tendencje w kondycji finansowej przedsiębiorstw są bardziej wyraźne i stabilne niż zmiany krótkoterminowe. Zmienna X58 wyróżnia się najniższymi wartościami IV we wszystkich horyzontach, przy czym po dyskretyzacji dla drugiego roku spada do wartości 0,04, co sugeruje marginalną przydatność w modelu dla czteroletniego horyzontu prognozy.

Tabela 11. Wartości IV zmiennych przed i po dyskretyzacji

	X5	X13	X22	X24	X25	X26	X27	X38	X39	X45	X46	X58
ROK 1 - przed	0,30	0,61	0,52	0,74	0,34	0,60	1,53	0,37	0,32	0,42	0,49	0,18
ROK 1 - po	0,25	0,55	0,21	0,61	0,32	0,51	1,49	0,32	0,26	0,38	0,41	0,12
ROK 2 - przed	0,23	0,28	0,27	0,44	0,25	0,35	1,19	0,28	0,27	0,18	0,40	0,10
ROK 2 - po	0,21	0,27	0,16	0,38	0,24	0,31	0,92	0,25	0,20	0,16	0,38	0,04
ROK 3 - przed	0,30	0,66	0,28	0,63	0,43	0,69	0,86	0,38	0,41	0,39	0,51	0,18
ROK 3 - po	0,24	0,51	0,24	0,54	0,40	0,69	0,85	0,35	0,35	0,36	0,40	0,15
ROK 4 - przed	0,29	0,64	0,41	0,62	0,47	0,69	0,90	0,45	0,58	0,51	0,62	0,27
ROK 4 - po	0,22	0,55	0,37	0,50	0,46	0,59	0,81	0,40	0,49	0,43	0,53	0,21
ROK 5 - przed	0,57	1,26	1,17	0,98	0,99	1,30	1,72	0,75	1,36	1,18	1,01	0,80
ROK 5 - po	0,34	0,95	1,12	0,75	0,90	0,01	1,59	0,67	1,34	0,89	0,83	0,67

Źródło: Opracowanie własne

3.3. Wyniki prognoz upadłości z różnym horyzontem czasowym

Wszystkie pięć modeli regresji logistycznej zostało zbudowanych w ujednolicony sposób. Celem było opracowanie narzędzi umożliwiających przewidywanie ryzyka bankructwa przedsiębiorstw z różnym horyzontem czasowym. Można oczekiwać, że im krótszy horyzont czasowy tym model powinien lepiej wykrywać bankrutów. Ze względu na silne niezbalansowanie klas w zbiorach danych, zastosowano 10-krotną walidację krzyżową. Tym sposobem próba została podzielona na 10 części i model jest trenowany 10 razy. Błąd predykcji jest oszacowywany poprzez wyliczenie średniej z wszystkich uzyskanych 10 wyników[69]. Dzięki walidacji krzyżowej każda obserwacja jest brana pod uwagę przy szacowaniu modelu oraz przy jego testowaniu. Podział zbioru na część uczącą i testową w proporcji 80/20, mógłby okazać się niewystarczającym rozwiązaniem w tym przypadku. Obserwacje należące do klasy bankrutów stanowią niewielki procent i losowy podział mógłby doprowadzić do niestabilnych i niereprezentacyjnych ocen modelu.

Modele budowano w programie Statistica z wykorzystaniem modułu kreatora regresji logistycznej. Istotność każdego predyktora weryfikowano testem ilorazu wiarygodności (LR) i wszystkie zmienne wykazały statystyczną istotność. Wszystkie wartości VIF dla predyktorów utrzymały się poniżej 5, wykluczając problem współliniowości. Jako metodę doboru

[69] Herman S., *Analiza porównawcza wybranych metod szacowania błędu predykcji klasyfikatora*, Przegląd Statystyczny, 4:449-463, 2016, s.452

zmiennych wybrano wszystkie efekty. Do porównywania modeli wykorzystano miarę AUC, test Hosmera - Lemeshowa, czułość, specyficzność, NPV, PPV oraz ACC.

W Tabeli 12 zestawiono kluczowe miary oceny wszystkich pięciu modeli w porządku zgodnym z chronologią okresu prognozowania - od najdłuższego horyzontu predykcji do najkrótszego.

Tabela 12. Podsumowanie miar ocen pięciu modeli regresji logistycznej

Miara oceny	**Model 1**	**Model 2**	**Model 3**	**Model 4**	**Model 5**
AUC	0,850	0,805	0,818	0,810	0,882
Punkt odcięcia	0,034	0,034	0,048	0,048	0,057
ACC	0,781	0,720	0,741	0,737	0,810
Czułość	0,779	0,726	0,736	0,741	0,811
Specyficzność	0,781	0,720	0,741	0,736	0,810
NPV	0,989	0,985	0,983	0,981	0,983
PPV	0,126	0,096	0,124	0,136	0,243
Test H-L (p wartość)	0,415	0,459	0,793	0,674	0,223

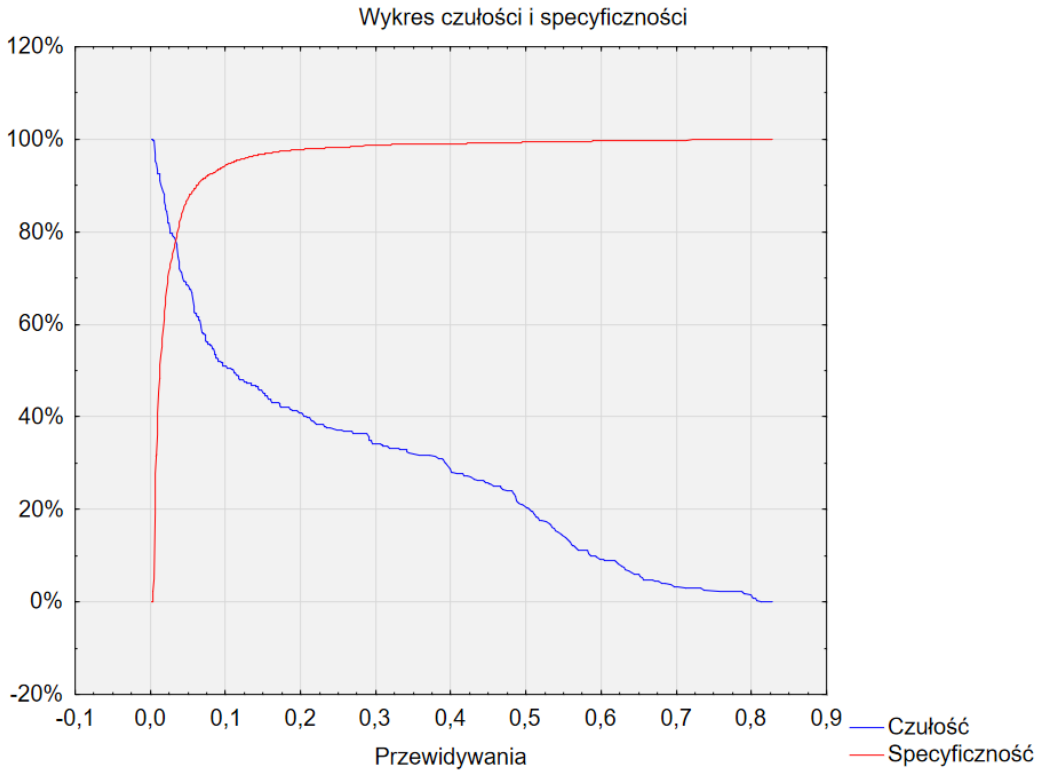
Źródło: Opracowanie własne

Model 1 zbudowano na danych z pierwszego roku okresu prognozowania, pięć lat przed wystąpieniem zdarzenia i jest to najdłuższy badany horyzont czasowy. Model na próbie testowej osiągnął wartość AUC równą 0,850. Oznacza to, że w 85% przypadków, model poprawnie przypisał wyższe prawdopodobieństwo bankructwa firmie rzeczywiście zagrożonej. Wynik ten jest uznawany za dobrą zdolność dyskryminacyjną modelu i jest szczególnie godny uwagi przy tak długim horyzoncie. Różnica między AUC na próbie uczącej, a testowej wyniosła zaledwie 0,009, co wyklucza zjawisko przeuczenia.

Punkt odcięcia wyznaczono jako punkt równowagi między czułością, a specyficznością i określono go na poziomie 0,034. Odpowiada to optymalnemu progowi prawdopodobieństw regresji logistycznej. Przy tym progu model osiąga czułość równą 77,9% co oznacza, że większość przedsiębiorstw, które w ciągu kolejnych pięciu lat zbankrutują, zostaje poprawnie zidentyfikowanych. NPV osiągnęła 98,9%, potwierdzając wysoką wiarygodność modelu w ocenie firm jako niezagrożonych. Spośród wszystkich firm które model oznaczył jako zagrożone bankructwem, jedynie 12,6% rzeczywiście zbankrutowało. Oznacza to że około 87%

alarmów generowanych przez model to fałszywe alarmy. Dla testu Hosmera-Lemeshowa p wartość = 0,415 i oznacza że model dobrze dopasowuje się do danych. Ogólna dokładność modelu wynosi 78,1%, jednak przy tak silnym niezbalansowaniu klas miara ta nie powinna być głównym kryterium oceny.

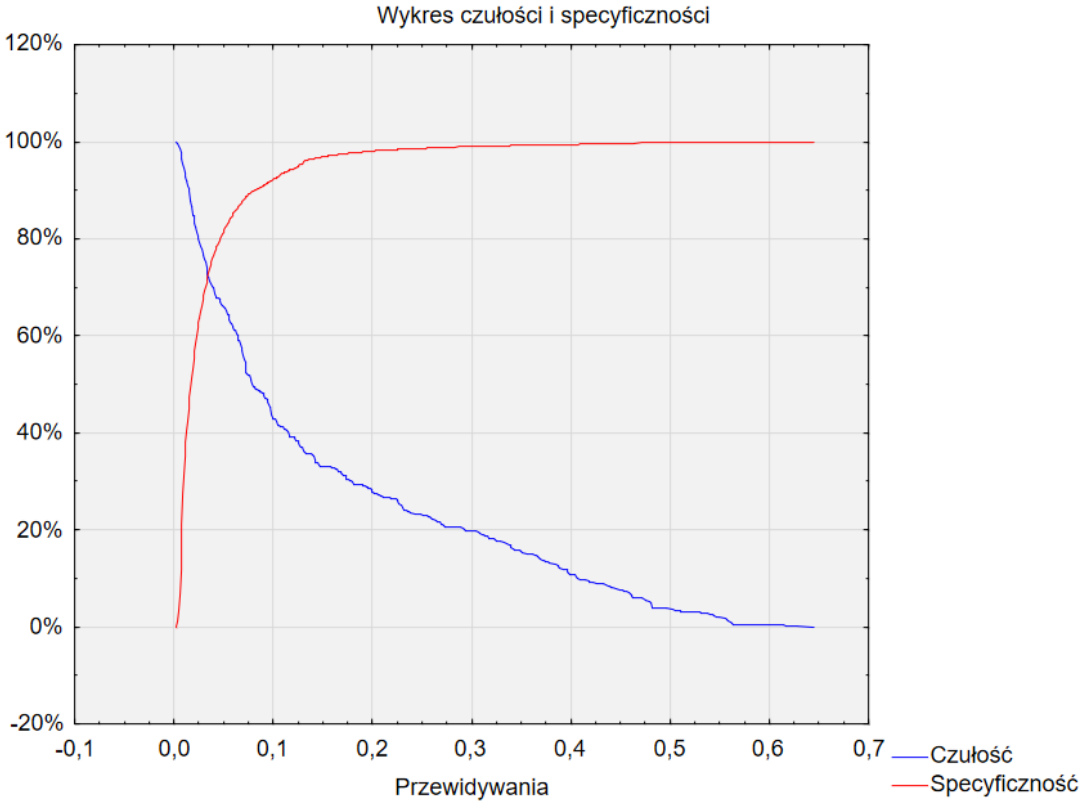
Wykres 3. Wykres funkcji czułości i specyficzności Modelu 1



Źródło: Opracowanie własne na podstawie przeprowadzonych badań.

Model 2 zbudowano na danych z drugiego roku okresu prognozowania, cztery lat przed wystąpieniem zdarzenia. Wartość AUC w walidacji krzyżowej wyniosła 0,805, co jest wynikiem nieco niższym niż w modelu 1. Model z prawdopodobieństwem 80,5% przypisał wyższe ryzyko bankructwa firmie faktycznie bankrutującej. Różnica między AUC na próbach wyniosła 0,007, co wyklucza zjawisko przeuczenia. Optymalny punkt odcięcia wyniósł 0,034, a czułość osiągnęła 72,6%. NPV utrzymała się na poziomie 98,5%. Z firmy, które model oznaczył jako zagrożone bankructwem, tylko 9,6% rzeczywiście zbankrutowało. Test Hosmera-Lemeshowa wykazał istotne statystycznie dopasowanie (p = 0,459). Dokładność modelu (ACC) wynosi 72%. Porównując wyniki z pierwszym modelem, ten model nie wykazuje lepszych zdolności predykcyjnych.

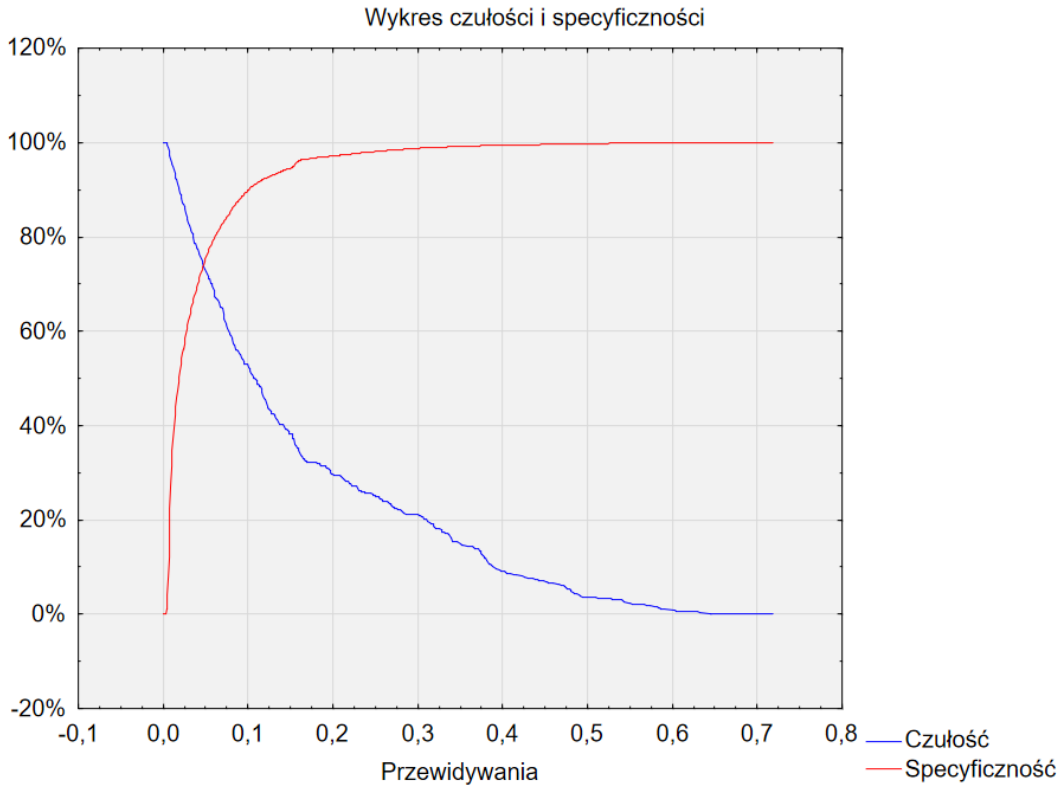
Wykres 4. Wykres funkcji czułości i specyficzności Modelu 2



Źródło: Opracowanie własne na podstawie przeprowadzonych badań.

Model 3 zbudowano na danych z trzeciego roku okresu prognozowania, trzy lat przed wystąpieniem zdarzenia. Model osiągnął AUC = 0,818 i jest to lepszy wyniki niż w modelu 2, ale gorszy niż w modelu 1. Różnica między AUC wykluczyła zjawisko przeuczenia (0.004). Optymalny punkt odcięcia określono na poziomie 0,048 i czułość osiągnęła 73,6%, czyli bardzo zbliżoną do modelu drugiego. Miara NPV nieznacznie się różni na tle pozostałych horyzontów (98,3%). Spośród firm, które model oznaczył jako zagrożone bankructwem, jedynie 12,4% realnie zbankrutowało. Test Hosmera-Lemeshowa wykazał istotne statystycznie dopasowanie, ponieważ wartość p = 0,793. Miara ACC osiągnęła wartość wyższą (na poziomie 74,1%) w porównaniu do drugiego modelu, ale niższą niż dla modelu pierwszego.

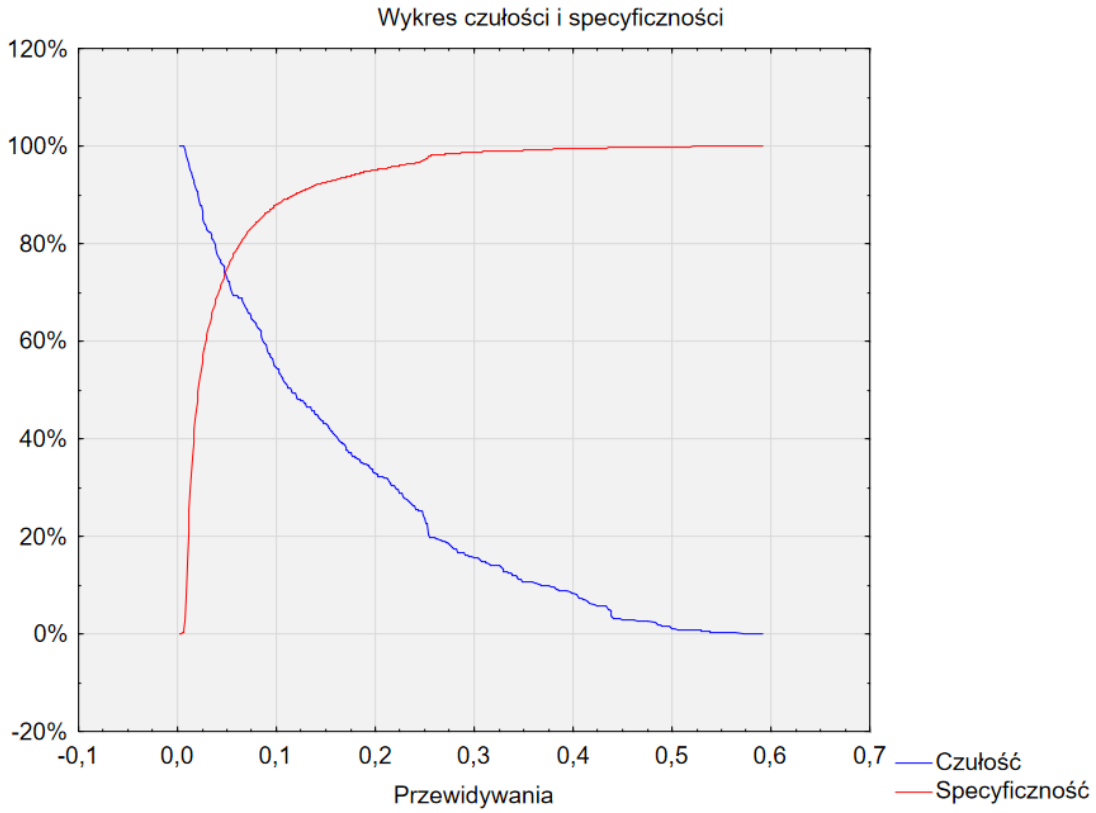
Wykres 5. Wykres funkcji czułości i specyficzności Modelu 3



Źródło: Opracowanie własne na podstawie przeprowadzonych badań.

Model 4 zbudowano na danych z drugiego roku okresu prognozowania, dwa lat przed wystąpieniem zdarzenia. Jest to horyzont istotny z perspektywy praktycznej. Dwa lata to zazwyczaj czas wystarczający na podjęcie działań restrukturyzacyjnych w firmie. AUC wyniosło 0,810, czyli jest to wynik gorszy niż w modelu 1 i modelu 3. Przeuczenie nie występuje, ponieważ różnica wyniosła 0,007. Optymalny punkt odcięcia wyznaczono na poziomie 0,048, z czułością równą 74,1%. NPV jest równe 0,981, a test Hosmera-Lemeshowa dał wynik p = 0,674, co oznacza brak podstaw do odrzucenia hipotezy zerowej o dobrym dopasowaniu modelu do danych. Z firmy, które model oznaczył jako zagrożone bankructwem, 13,6% rzeczywiście zbankrutowało. Dokładność modelu osiągnęła wartość 73,7% i jest to również wynik gorszy niż w modelu 1 i modelu 3.

Wykres 6. Wykres funkcji czułości i specyficzności Modelu 4

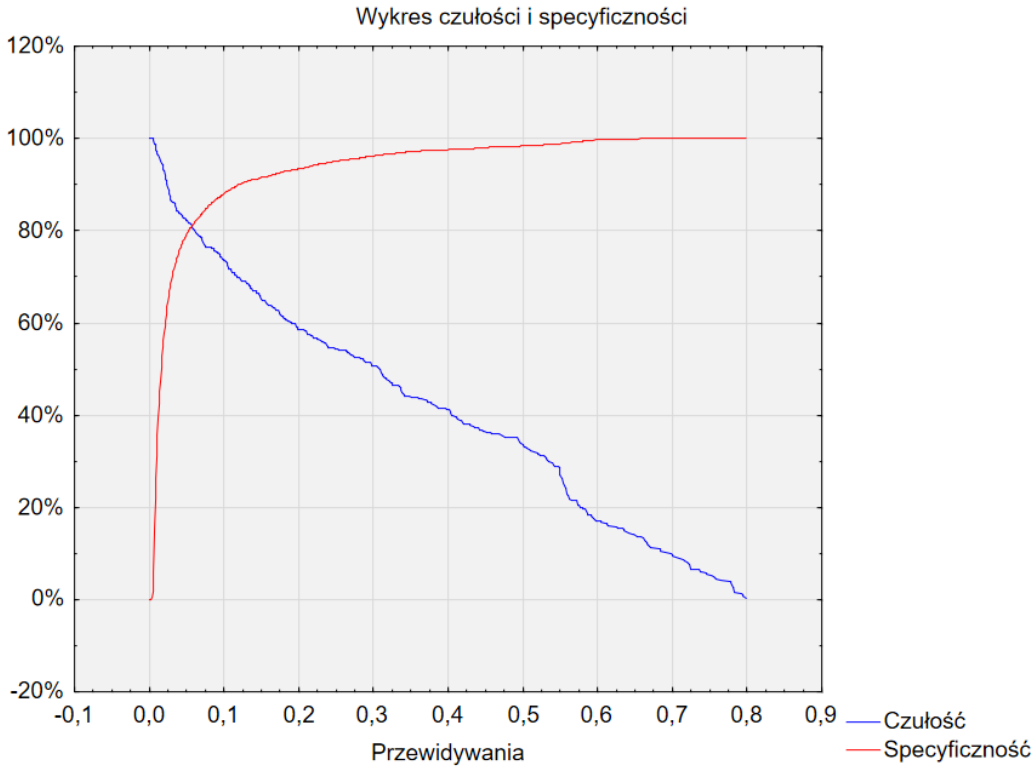


Źródło: Opracowanie własne na podstawie przeprowadzonych badań.

Model 5 zbudowano na danych z piątego roku okresu prognozowania, umożliwia wykrycie zagrożenia bankructwem z najkrótszym horyzontem: zaledwie jeden rok przed wystąpieniem zdarzenia. Dane z tego okresu powinny zawierać najbardziej wyraźne i bezpośrednie sygnały o możliwym bankructwie przedsiębiorstwa.

Zgodnie z oczekiwaniami wynikającymi z logiki skracania horyzontu predykcji, model osiągnął najwyższą wartość AUC = 0,882. W 88,2% przypadków, model poprawnie przypisał wyższe prawdopodobieństwo bankructwa firmie rzeczywiście zagrożonej. Zjawisko przeuczenia nie wystąpiło (różnica wyniosła 0,005). Czułość osiągnęła 81,1%, czyli wartość wyraźnie wyższą niż w modelach 1-4. To potwierdza, że sygnały finansowe rok przed bankructwem są znacząco silniejsze i łatwiejsze do uchwycenia przez model. Optymalny punkt odcięcia wyniósł 0,057 i jest najwyższy spośród wszystkich modeli. Test Hosmera-Lemeshowa wykazał istotne statystycznie dopasowanie (p = 0,223). Miara NPV wyniosła 98,3%, a dokładność modelu 81%. Ze wszystkich firm, które model oznaczył jako zagrożone bankructwem, 24,3% to faktycznie złe firmy - najwyższe PPV ze wszystkich modeli.

Wykres 7. Wykres funkcji czułości i specyficzności Modelu 5



Źródło: Opracowanie własne na podstawie przeprowadzonych badań.

Uzyskane wyniki pozwalają na sformułowanie kilku istotnych obserwacji. Wartości AUC we wszystkich pięciu modelach mieszczą się w przedziale 0,805 - 0,882, więc wykazują dobrą zdolność dyskryminacyjną. Pozytywne wyniki testu Hosmera-Lemeshowa, wskazują na właściwe dopasowanie do danych we wszystkich przypadkach. Oznacza to, że zestaw wybranych wskaźników finansowych, skutecznie różnicuje przedsiębiorstwa zagrożone niewypłacalnością od podmiotów stabilnych finansowo. Żaden z modeli nie wykazuje objawów przeuczenia, co potwierdza skuteczność zastosowanej 10-krotnej stratyfikowanej walidacji krzyżowej. Nie pojawia się tutaj monotoniczny trend wzrostowy wraz ze skracaniem horyzontu. Najwyższą skutecznością predykcyjną charakteryzuje się model 5 (AUC = 0,882, czułość 81,1%), oparty na danych z roku poprzedzającego bankructwo. Znaczącą różnicę można zauważyć między Modelem 1 (5-letni horyzont), a Modelem 2 (4-latni horyzont). Model 1 osiąga lepsze wyniki we wszystkich miarach mimo dłuższego horyzontu.

W porównaniu z wynikami przedstawionymi przez Ziębę i in. (2016) oraz Xiaomao i in. (2019), modele regresji logistycznej osiągnęły niższe wartości AUC niż zaawansowane algorytmy oparte na XGBoost i metodach zespołowych, które uzyskiwały AUC przekraczające 0,94. Różnica ta wskazuje na przewagę metod wykorzystujących nieliniowe zależności oraz

mechanizmy boostingowe w zadaniach predykcji bankructwa. We wszystkich trzech badaniach najwyższą skuteczność predykcyjną osiągnął model oparty na danych z roku bezpośrednio poprzedzającego upadłość, co potwierdza, że sygnały finansowe stają się wyraźniejsze wraz ze zbliżaniem się do momentu bankructwa. Prawidłowość ta jest szczególnie wyraźna w przypadku regresji logistycznej, co sugeruje, że metoda ta jest wyjątkowo wrażliwa na jakość i siłę dostępnych sygnałów finansowych. Interesującą obserwacją jest fakt, że zarówno w niniejszym badaniu, jak i w analizowanych pracach, najwyższe wartości AUC uzyskano dla zbiorów 1stYear oraz 5thYear. Dodatkowo w badaniach przedstawionych przez autorów, jak i w niniejszej pracy, model z 5-letnim horyzontem uzyskał lepsze wyniki niż model z 4-letnim horyzontem. Najniższa skuteczność występowała dla okresów 2ndYear - 4thYear. Sugeruje to, że informacje finansowe zawarte w danych z pierwszego oraz ostatniego roku analizowanego horyzontu prognostycznego posiadają największą wartość predykcyjną w ocenie ryzyka bankructwa przedsiębiorstw.

Zakończenie

Celem niniejszej pracy było zbadanie roli horyzontu czasowego w prognozowaniu upadłości przedsiębiorstw przy użyciu modeli regresji logistycznej. Przeprowadzona analiza empiryczna pozwoliła na sformułowanie wniosków odnoszących się do postawionych pytań badawczych. Wszystkie pięć skonstruowanych modeli wykazało dobrą zdolność dyskryminacyjną i właściwe dopasowanie do danych w każdym przypadku. Najwyższą skutecznością predykcyjną charakteryzował się model oparty na danych z roku bezpośrednio poprzedzającego bankructwo, co jest wynikiem zgodnym z oczekiwaniami. Sygnały finansowe zbliżającej się niewypłacalności są wówczas najpełniej uwidocznione w sprawozdaniach finansowych.

Kluczowym i nieoczekiwanym wynikiem badania jest brak monotonicznego trendu wzrostowego skuteczności wraz ze skracaniem horyzontu. Lepsze wyniki modelu z 5-letnim horyzontem niż 4-letnim, może wynikać z różnic w składzie i liczebności prób lub ze specyfiki okresu obserwacji i wymaga pogłębionej analizy w przyszłych badaniach. Obserwacja ta sugeruje, że zarówno bardzo wczesne sygnały finansowe, jak i te bezpośrednio poprzedzające upadłość, są przez model dobrze wychwytywane.

Prezentowane badanie charakteryzuje się pewnymi ograniczeniami metodycznymi oraz empirycznymi. Uzyskane wyniki odnoszą się do specyficznego zbioru danych obejmującego polskie przedsiębiorstwa, zatem możliwość ich uogólnienia na inne rynki geograficzne czy gałęzie gospodarki wymaga dalszej weryfikacji. Ponadto skład oraz liczebność prób w poszczególnych horyzontach czasowych nie były tożsame, co mogło rzutować na porównywalność wyników między modelami. Warto również wskazać, iż analiza bazuje wyłącznie na wskaźnikach ilościowych pochodzących ze sprawozdań finansowych. Pominięto w niej czynniki jakościowe (takie jak kompetencje kadry zarządzającej czy pozycja konkurencyjna podmiotu) oraz zmienne makroekonomiczne (np. stopy procentowe, stopa inflacji), które mogą wykazywać istotną siłę predykcyjną. Algorytm Random Forest wykorzystano jedynie do wstępnej selekcji predyktorów na potrzeby modeli regresji logistycznej. Zastosowanie metod uczenia maszynowego w charakterze samodzielnych klasyfikatorów, pozwoliłoby na porównanie ich skuteczności predykcyjnej z przyjętym podejściem scoringowym.

Reasumując, przeprowadzone badanie dostarcza empirycznych dowodów na to, że horyzont czasowy odgrywa istotną, choć niejednoznaczną rolę w prognozowaniu upadłości przedsiębiorstw. Skracanie horyzontu nie prowadzi automatycznie do monotonicznego wzrostu skuteczności modeli. Uzyskane wyniki pokazują jednocześnie, że odpowiednio skonstruowane modele scoringowe oparte na regresji logistycznej z transformacją WoE, są w stanie wykrywać sygnały zagrożenia niewypłacalnością nawet przy długich horyzontach prognostycznych.

Bibliografia

1. Adamus R., *Prawo upadłościowe. Komentarz wydanie 3*, Wydawnictwo C.H.Beck, Warszawa 2021
2. Altman E. I., *Financial Ratios, Discriminant Analysis and the Prediction of Corporate Bankruptcy.* The Journal of Finance, 23(4), 1968
3. Antonowicz P., *Bankructwa i upadłości przedsiębiorstw*, Wydawnictwo Uniwersytetu Gdańskiego 2015
4. Artienwicz N., Bartoszewicz A., Cygańska M., Wójtowicz P., *Kształtowanie wyniku finansowego w Polsce. Teoria - praktyka - stan badań.,* Wydawnictwo IUS PUBLICUM, Katowice 2020
5. Bartochowska D., Woźniak J., *Wybrane zagadnienia zarządzania przedsiębiorstwem*, Wydawnictwo Politechniki Łódzkiej, Łódź 2022
6. Bazeli B., *„Dlaczego prognozy ekonomiczne są nietrafne?"*, Zeszyty Naukowe Kujawsko-Pomorskiej Szkoły Wyższej w Bydgoszczy, 2017
7. Beaver H., *Financial Ratios as Predictors of Failure*, Journal of Accounting Research 4, 1966
8. Boateng, E. Y., Abaye, D. A., *A review of the logistic regression model with emphasis on medical research.* Journal of Data Analysis and Information Processing, 7, 2019
9. Boratyńska K., *The Scale Of Corporate Bankruptcies During The Covid-19 Pandemic*, Warsaw University of Life Sciences SGGW, 2022
10. Chatterjee S., Hadi A.S., *Regression Analysis by Example. 5th Edition*, Wiley, New York 2012
11. Cieślak M., *Prognozowanie gospodarcze. Metody i zastosowania*., Wydawnictwo Naukowe PWN Warszawa 2008
12. Cieślak M., *„Prognozy: trafność a horyzont",* Zeszyty Naukowe Wyższej Szkoły Bankowej we Wrocławiu 15, nr 5 (2015)
13. Elliott G., Timmermann A., *Forecasting in Economics and Finance. Annual Review Economics.* 8:81-110, 2016
14. Fisher R.A., *The Use of Multiple Measurements in Taxonomic Problems, „Annals of Eugenics*" 1936, vol. 7
15. Gil I. (red.), *Meritum. Postępowania restrukturyzacyjne. Postępowanie upadłościowe*, Wolters Kluwer Polska, Warszawa 2025.
16. Gitman, Lawrence J., Carl McDaniel, Amit Shah, Monique Reece, Linda Koffel, Bethann Talsma, and James C. Hyatt. *Introduction to Business*, Houston, OpenStax, 2018.
17. Herman S., *Analiza porównawcza wybranych metod szacowania błędu predykcji klasyfikatora*, Przegląd Statystyczny, 4:449-463, 2016
18. Hołda A., Strojny K., *Determinanty upadłości przedsiębiorców w Polsce - systematyka i badanie komparatywne opinii kadry zarządzającej i syndyków,* Zeszyty Teoretyczne Rachunkowości tom 101 (157), 2019
19. Jackowska B., *Efekty interakcji między zmiennymi objaśniającymi w modelu logitowym w analizie zróżnicowania ryzyka zgonu*, „Przegląd Statystyczny" 2011, z. 1-2
20. Kopczyński P., *Metody prognozowania upadłości wykorzystywane w praktyce przez polskie przedsiębiorstwa - wyniki badań ankietowych,* „Zeszyty Teoretyczne Rachunkowości" tom 89 (145), 2016
21. Korol T., *Systemy ostrzegania przedsiębiorstw przed ryzykiem upadłości*., Wolters Kluwer Polska SA, 2010

22. Korol T., Prusak B., *Upadłość przedsiębiorstw a wykorzystanie sztucznej inteligencji*, Wydanie IV zmienione, CeDeWu Warszawa 2022
23. Maciąg A., Pietroń R., Kukla S., *Prognozowanie i symulacja w przedsiębiorstwie*., Warszawa PWE, 2013, s. 25
24. Mann H., Whitney D., *On a test of whether one of two random variables is stochastically larger than the other.* Annals of Mathematical Statistics, 1947
25. Mączyńska E., Zawadzki M., *Dyskryminacyjne modele predykcji bankructwa przedsiębiorstw*, „Ekonomista" 2006, nr 2
26. Mączyńska E., *Ocena ryzyka upadłości przedsiębiorstwa [w:] Ryzyko w działalności przedsiębiorstw. Wybrane aspekty*, red. A. Fierla, Szkoła Główna Handlowa w Warszawie - Oficyna Wydawnicza, Warszawa 2009
27. Mączyńska E., *Wierzytelności - fundamentalna kwestia ekonomiczna i prawna*. Biuletyn nr 2(77) 2017.
28. Pociecha J., Pawełek B., Baryła M., Augustyn S., *Statystyczne metody prognozowania bankructwa w zmieniającej się koniunkturze gospodarczej*, Fundacja Uniwersytetu Ekonomicznego, Kraków 2014
29. Prusak B., *Nowoczesne metody prognozowania zagrożenia finansowego przedsiębiorstw.*, Wydawnictwo Naukowe PWN, Warszawa 2005
30. Prusak B., Morawska S., Łukowski M., Banasik P., *The impact of bankruptcy regimes on entrepreneurship and innovation. Is there any relationship?,* International Entrepreneurship and Management Journal, 2021
31. Raczkiewicz D., *Zastosowanie analizy regresji w reprezentacyjnych badaniach społeczno-gospodarczych*, Ekonometria 51:31-47, 2016
32. Rojas H., Alvarez C., Rojas N., *Statistical Hypothesis Testing for Information Value (IV)*, Journal of Statistical Theory and Applications, 24:1196-1216, 2025
33. Sathyanarayanan S., Tantri B. R., *Confusion matrix-based performance evaluation metrics*., African Journal of Biomedical Research 2024, 27(4S)
34. Shumway T., *Forecasting Bankruptcy More Accurately: A Simple Hazard Model*, The Journal of Business 74, nr 1 (2001)
35. Tokarski A., Matuszak M., *Upadłość jako instytucja gospodarki rynkowej*, PE 2016, 12, 199-216.
36. Tokarski M., Tokarski A., *Bankructwa. Tom 3. Przedsiębiorstwa i konsumenci*., Difin 2023
37. Witkowski M., Klimanek T., *Prognozowanie gospodarcze i symulacje w przykładach i zadaniach*, Akademia Ekonomiczna, Poznań 2006
38. Zięba M., Tomczak S., Tomczak J., *Ensemble Boosted Trees with Synthetic Features Generation in Application to Bankruptcy Prediction*, Expert Syst. Appl., 58, 93-101, 2016
39. Xia Xiaomao, Zhang Xudong i Wang Yuanfang, *„A Comparison of Feature Selection Methodology for Solving Classification Problems in Finance"*, Journal of Physics: Conference Series 1284 (2019): 012026

Akty prawne

1. Kodeks cywilny z dnia 23 kwietnia 1964 r., art. 55. (Dz.U. 2025, poz. 1071)
2. Ustawa z dnia 6 marca 2018 r., *Prawo przedsiębiorców*, Art. 7 ust. 2 (Dz. U. 2018 poz. 646)
3. Ustawa z dnia 28 lutego 2003 r. - Prawo upadłościowe, art. 11 ust. 1
4. Ustawa z dnia 28 lutego 2003 r. - Prawo upadłościowe, Art. 11 ust. 1a

5. Ustawa z dnia 28 lutego 2003 r. - Prawo upadłościowe, Art. 13
6. Ustawa z dnia 28 lutego 2003 r. - Prawo upadłościowe, Art. 20 ust. 2.
7. Ustawa z dnia 28 lutego 2003 r. - Prawo upadłościowe, Art. 22a
8. Ustawa z dnia 28 lutego 2003 r. - Prawo upadłościowe, Art. 26 ust. 1. (Dz.U. z 2025 r. poz. 614)
9. Ustawa z dnia 28 lutego 2003 r. - Prawo upadłościowe, Art. 62 ust. 1. (Dz.U. z 2025 r. poz. 614)
10. Ustawa z dnia 15 maja 2015 r. - Prawo restrukturyzacyjne, Art. 3 pkt. 1,2,3,4,5 (Dz.U. 2015 poz. 978)
11. Ustawa z dnia 15 maja 2015 r. - Prawo restrukturyzacyjne, Art. 76 pkt.1 (Dz.U.2024.1428)
12. Zalecenie Komisji z dnia 6 maja 2003 r. dotyczące definicji przedsiębiorstw mikro, małych i średnich; Załącznik, definicja przedsiębiorstw mikro, małych i średnich przyjęta przez komisję, Art. 2
13. Art.61 prawo upadłościowe

Źródła internetowe

1. https://mfiles.pl/pl/index.php/Formy_w%C5%82asno%C5%9Bci dostęp z dnia 25.10.2025
2. https://innovatree.pl/klasyfikacja-przedsiebiorstw-i-rodzaje-dzialalnosci-gospodarczej/ dostęp z dnia 25.10.2025
3. Postępowania upadłościowe i restrukturyzacyjne. Raport 2025 - MGBI dostęp z dnia 02.11.2025
4. https://businessinsider.com.pl/gielda/przyczyny-upadku-banku-lehman-brothers/p11peh7, dostęp z dnia 16.12.2025
5. https://odszkodowaniepowypadkowe.pl/co-sie-dzieje-z-akcjami-po-ogloszeniu-upadlosci/, dostęp z dnia 16.12.2025
6. https://www.zubkowska.pl/upadlosci.php?c=60, dostęp z dnia 18.01.2026
7. Raport Polski mikro, mały i średni biznes w obliczu pandemii COVID-19. Przychody, płynność i reakcja na wstrząs, PwC, 2020, polski-mikro-maly-sredni-biznes-w-obliczu-pandemii.pdf, dostęp z dnia 24.01.2026
8. *Postępowania upadłościowe i restrukturyzacyjne. Raport 2025*, MGBI, https://www.mgbi.pl/raporty/tresc/postepowania-upadlosciowe-i-restrukturyzacyjne-raport-2025/, dostęp z dnia 24.01.2026
9. Link do danych: https://archive.ics.uci.edu/dataset/365/polish+companies+bankruptcy+data, , data pobrania: 03.04.2025r.

Spis tabel

Tabela 1. Rozpatrzenie wniosków o ogłoszenie upadłości - uzasadnienie i podstawa prawna..9
Tabela 2. Podział metod prognozowania upadłości przedsiębiorstw 20
Tabela 3. Metodologia zbierania danych treningowych 33
Tabela 4. Zestaw zmiennych występujący w zbiorze danych.....34
Tabela 5. Rozkład braków danych w poszczególny zbiorach.....36

Tabela 6. Wyniki testu U Manna - Whitneya oraz statystyki opisowe zmiennej zależnej *liczba braków* oraz zmiennej grupującej *class* 37
Tabela 7. Zmienne objaśniające wyeliminowane na podstawie kryterium IV 39
Tabela 8. Ranking zmiennych wybranych za pomocą modeli Random Forest 40
Tabela 9. Pary zmiennych silnie skorelowane we wszystkich zbiorach danych 41
Tabela 10. Przedziały dyskretyzacji oraz kierunek trendu WoE zmiennych objaśniających 42
Tabela 11. Wartości IV zmiennych przed i po dyskretyzacji 43
Tabela 12. Podsumowanie miar ocen pięciu modeli regresji logistycznej 44

Spis wykresów

Wykres 1. Upadłości przedsiębiorstw według branż w latach 2018-2021 w Polsce 16
Wykres 2. Procentowy rozkład zmiennej *class* w zbiorach danych 36
Wykres 3. Wykres funkcji czułości i specyficzności Modelu 1 45
Wykres 4. Wykres funkcji czułości i specyficzności Modelu 2 46
Wykres 5. Wykres funkcji czułości i specyficzności Modelu 3 47
Wykres 6. Wykres funkcji czułości i specyficzności Modelu 4 48
Wykres 7. Wykres funkcji czułości i specyficzności Modelu 5 49

Spis ilustracji

Ilustracja 1. Etapy procesu prognozowania 21